МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ТЕХНОЛОГИЧЕСКИЙ УНИВЕРСИТЕТ «МИСИС»

ИНСТИТУТ КОМПЬЮТЕРНЫХ НАУК (ИКН)

Курсовая работа на тему «Алгоритм Бойера-Мура для поиска подстроки в строке»

Выполнил: студент группы БИВТ-23-4
Борисенко Павел Дмитриевич

Москва 2025

Содержание

1.Введение

Алгоритм Бойера-Мура, разработанный двумя учеными — Бойером (Robert S. Boyer) и Муром (J. Strother Moore), считается наиболее быстрым среди алгоритмов общего назначения, предназначенных для поиска подстроки в строке. Важной особенностью алгоритма является то, что он выполняет сравнения в шаблоне справа налево в отличие от многих других алгоритмов.

Он использует два эвристических правила — правило плохого символа и правило хорошего суффикса — для пропуска заведомо неподходящих участков текста, что ускоряет поиск.

Алгоритм Бойера-Мура считается наиболее эффективным алгоритмом поиска шаблонов в стандартных приложениях и командах, таких как Ctrl+F в браузерах и текстовых редакторах.

2. Описание алгоритма

Идея алгоритма:

•Сравнивает подстроку с текстом справа налево.
•При несовпадении символов использует правила для сдвига подстроки.

Алгоритм сравнивает символы шаблона X справа налево, начиная с самого правого, один за другим с символами исходной строки Y. Если символы совпадают, производится сравнение предпоследнего символа шаблона и так до конца. Если все символы шаблона совпали с наложенными символами строки, значит, подстрока найдена, и поиск окончен. В случае несовпадения какого-либо символа (или полного совпадения всего шаблона) он использует две предварительно вычисляемых эвристических функций, чтобы сдвинуть позицию для начала сравнения вправо.

Таким образом для сдвига позиции начала сравнения алгоритм Бойера-Мура выбирает между двумя функциями, называемыми эвристиками хорошего суффикса и плохого символа (иногда они называются эвристиками совпавшего суффикса и стоп-символа). Так как функции эвристические, то выбор между ними простой — ищется такое итоговое значение, чтобы мы не проверяли максимальное число позиций и при этом нашли все подстроки равные шаблону.

Алфавит обозначим буквой Σ.
Пусть |y|=n|y|=n, |x|=m|x|=m и |Σ|=σ|Σ|=σ.

Предположим, что в процессе сравнения возникает несовпадение между символом x[i]=ax[i]=a шаблона и символом y[i+j]=by[i+j]=b исходного текста при проверке в позиции jj. Тогда x[i+1…m−1]=y[i+j+1… j+m−1]=ux[i+1… m−1]=y[i+j+1…j+m−1]=u и x[i]≠y[i+j]x[i]≠y[i+j], и m−i−1m−i−1 символов шаблона уже совпало.

Правило сдвига хорошего суффикса

Если при сравнении текста и шаблона совпало один или больше символов, шаблон сдвигается в зависимости от того, какой суффикс совпал.

Если существуют такие подстроки равные U, что они полностью входят в X и идут справа от символов, отличных от x[i]x[i], то сдвиг происходит к самой правой из них, отличной от U. Понятно, что таким образом мы не пропустим никакую строку, так как сдвиг просходит на следующую слева подстроку U от суффикса. После выравнивания шаблона по этой подстроке сравнение шаблона опять начнется с его последнего символа. На новом шаге алгоритма можно строку U, по которой был произведён сдвиг, не сравнивать с текстом — возможность для модификации и дальнейшего ускорения алгоритма.

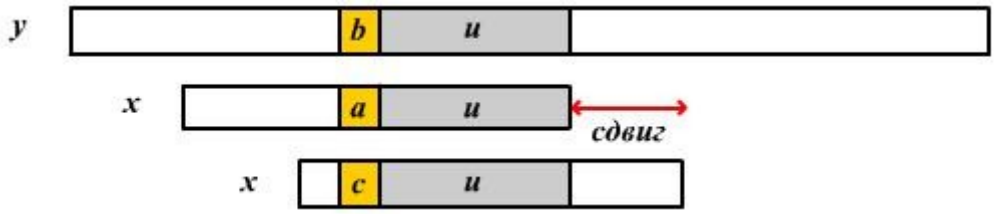

Если не существует таких подстрок, то смещение состоит в выравнивании самого длинного суффикса Y подстроки y[i+j+1…j+m−1]y[i+j+1…j+m−1] с соответствующим префиксом X. Из-за того, что мы не смогли найти такую подстроку, то, очевидно, что ни один суффикс шаблона X уже не будет лежать в подстроке y[i+j+1…j+m−1]y[i+j+1…j+m−1], поэтому единственный вариант, что в эту подстроку попадет префикс.

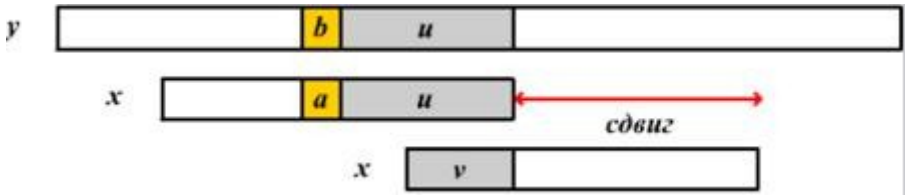

Правило сдвига плохого символа

В таблице плохих символов указывается последняя позиция в шаблоне (исключая последнюю букву) каждого из символов алфавита. Для всех символов, не вошедших в шаблон, пишем M. Предположим, что у нас не совпал символ C из текста на очередном шаге с символом из шаблона. Очевидно, что в таком случае мы можем сдвинуть шаблон до первого вхождения этого символа C в шаблоне, потому что совпадений других символов точно не может быть. Если в шаблоне такого символа нет, то можно сдвинуть весь шаблон полностью.

Если символ исходного текста y[i+j]y[i+j] встречается в шаблоне X, то происходит его выравнивание с его самым правым появлением в подстроке x[0…m−2]x[0…m−2].

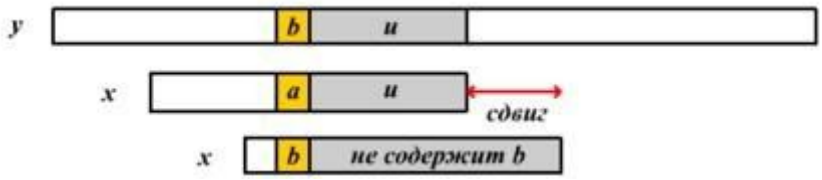

Если y[i+j]y[i+j] не встречается в шаблоне X, то ни одно вхождение X в Y не может включать в себя y[i+j]y[i+j], и левый конец окна сравнения совмещен с символом непосредственно идущим после y[i+j]y[i+j], то есть символ y[i+j+1]y[i+j+1].

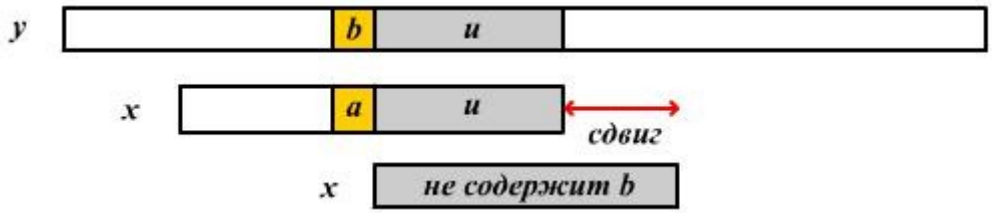

Обратите внимание, что сдвиг плохого символа может быть отрицательным, поэтому исходя из ранее приведенных свойств этих функций берется значение равное максимуму между сдвигом хорошего суффикса и сдвигом плохого символа.

Псевдокод

```
function boyer_moor(text, pattern):
    n = длина(text)
    m = длина(pattern)
    if m == 0:
        return 0
    # Предварительная обработка правил
    bad_char = таблица_плохих_символов(pattern)
    good_suffix = таблица_хороших_суффиксов(pattern)
    s = 0
    while s <= n - m:
        j = m - 1
        while j >= 0 and pattern[j] == text[s + j]:
            j -= 1
        if j < 0:
            return s  # Найдено совпадение
        else:
            s += max(bad_char[text[s + j]] - (m - 1 - j), good_suffix[j])
    return -1  # Совпадений нет
```

Пример:

Пусть нам дана строка y=GCATCGCAGAGAGTATACAGTACGи образец x=GCAGAGAG.

Построим массивы bmBc и bmGs :

a	A	C	G	T
$bmBc[a]$	1	6	2	8

i	0	1	2	3	4	5	6	7
$x[i]$	G	C	A	G	A	G	A	G
$suff[i]$	1	0	0	2	0	4	0	8
$bmGs[i]$	7	7	7	2	7	4	7	1

Изображение	$(j, bmGs[y[j]])$	Описание
G C A T C G C **A** G A G A G T A T A C A G T A C G 1 G C A G A G A **G**	$(7, 1)$	Сравниванием последние символы, они неравны, поэтому сдвигаемся на $bmGs[y[j]]$, где $y[j]$ — это не совпавший символ. В данном случае $y[j] = 7$, а $bmGs[7] = 1$.
G C A T C G **C** A G A G A G T A T A C A G T A C G 3 2 1 G C A G A **G** A G	$(8, 4)$	Последние символы совпали. Предпоследние совпали. Третьи символы с конца различны, сдвигаемся на $bmGs[5] = 4$.
G C A T C **G C A G A G A G** T A T A C A G T A C G 8 7 6 5 4 3 2 1 G C A G A G A G	$(12, 7)$	Последние символы совпали, сравниваем далее. Строчка найдена. Продолжаем работу и сдвигаемся на $bmGs[0] = 7$.
G C A T C G C A G A G A G T A T A **C** A G T A C G 3 2 1 G C A G A **G** A G	$(19, 4)$	Последние символы совпали. Предпоследние совпали. Третьи символы с конца различны, сдвигаемся на $bmGs[5] = 4$.
G C A T C G C A G A G A G T A T A C A G T A **C** G 2 1 G C A G A G **A** G	$(23, 7)$	Последние символы совпали, предпоследние различны. Алгоритм закончил работу.

В итоге, чтобы найти одно вхождение образца длиной m=8 в образце длиной n=24, нам понадобилось 17 сравнений символов.

3.Анализ алгоритма

Корректность:
Алгоритм гарантированно находит все вхождения подстроки благодаря правилам сдвига, которые не пропускают возможные совпадения.

Временная сложность:

•В лучшем случае: O(n/m)
•В худшем случае: O(n*m)
•На практике близок к O(n) для естественных текстов.

Память: O(m) для хранения таблиц.

Достоинства

Алгоритм Бойера-Мура на хороших данных очень быстр, а вероятность появления плохих данных крайне мала. Поэтому он оптимален в большинстве случаев, когда нет возможности провести предварительную обработку текста, в котором проводится поиск.
На больших алфавитах (относительно длины шаблона) алгоритм чрезвычайно быстрый и требует намного меньше памяти, чем алгоритм Ахо-Корасик)).
Позволяет добавить множество модификаций, таких как поиск подстроки, включающей *любой символ (?)* (но для реализации *множества символов (*)* не подходит, так как длина шаблона должна быть известна заранее).

Недостатки

Алгоритмы семейства Бойера-Мура не расширяются до приблизительного поиска, поиска любой строки из нескольких.
На больших алфавитах (например, Юникод) может занимать много памяти. В таких случаях либо обходятся хэш-таблицами, либо дробят алфавит, рассматривая, например, 4-байтовый символ как пару двухбайтовых.
На искусственно подобранных неудачных текстах скорость алгоритма Бойера-Мура серьёзно снижается.

4. Реализация

```python
def boyer_moore(text, pattern):
    """
    Реализация алгоритма Бойера-Мура для поиска подстроки.
    Возвращает список позиций всех вхождений pattern в text.
    """
    def preprocess_bad_char(pattern):
        """
        Создает таблицу плохих символов (bad character rule).
        Ключ - символ, значение - последняя позиция символа в шаблоне.
        """
        bad_char = {}
        length = len(pattern)
        for i in range(length):
            bad_char[pattern[i]] = i
        return bad_char

    def preprocess_good_suffix(pattern):
        """
        Создает таблицу хороших суффиксов (good suffix rule).
        """
        length = len(pattern)
        bmGs = [0] * length
        suffix = [0] * (length + 1)

        # Первый этап: вычисление suffix
        suffix[length] = length
        for i in range(length-1, -1, -1):
            j = i
            while j >= 0 and pattern[j] == pattern[length - 1 - i + j]:
                j -= 1
            suffix[i] = i - j

        # Второй этап: заполнение bmGs
        for i in range(length):
            bmGs[i] = length
        j = 0
        for i in range(length-1, -1, -1):
            if suffix[i] == i + 1:
                while j < length - 1 - i:
                    if bmGs[j] == length:
                        bmGs[j] = length - 1 - i
                    j += 1
        for i in range(length-1):
            bmGs[length - 1 - suffix[i]] = length - 1 - i

        return bmGs
```

```
    # Основная функция
    n = len(text)
    m = len(pattern)
    if m == 0:
        return []

    # Предварительная обработка
    bad_char = preprocess_bad_char(pattern)
    bmGs = preprocess_good_suffix(pattern)

    result = []
    s = 0  # Текущая позиция сравнения в тексте

    while s <= n - m:
        j = m - 1
        # Сравниваем справа налево
        while j >= 0 and pattern[j] == text[s + j]:
            j -= 1

        if j < 0:
            # Найдено совпадение
            result.append(s)
            # Сдвигаемся на длину шаблона (аналог bmGs[0])
            s += bmGs[0]
        else:
            # Вычисляем сдвиг по правилу плохого символа
            bc_shift = j - bad_char.get(text[s + j], -1)
            # Вычисляем сдвиг по правилу хорошего суффикса
            gs_shift = bmGs[j]
            # Выбираем максимальный сдвиг
            s += max(bc_shift, gs_shift, 1)

    return result

# Пример использования
text = "GCATCGAGAGAGAGTATACAGTACGCAGAGAG"
pattern = "GCAGAGAG"

positions = boyer_moore(text, pattern)
print("Найденные позиции:", positions)  # Должно вывести [8, 19]
```

Данный код реализует алгоритм Бойера-Мура для эффективного поиска подстроки в строке. Алгоритм использует два основных правила для оптимизации поиска:

1.**Правило плохого символа**:

•Создается таблица bad_char, которая для каждого символа шаблона запоминает его последнюю позицию.

•При несовпадении символов это правило позволяет сдвинуть шаблон на максимально возможное расстояние.

2.**Правило хорошего суффикса:**

•Создается таблица bmGs, которая учитывает совпадения суффиксов шаблона.

•Это правило помогает определить оптимальный сдвиг, если часть шаблона уже совпала с текстом.

Основные шаги алгоритма:

1.**Предварительная обработка**:

•Формируются таблицы bad_char и bmGs для шаблона.

2.**Поиск в тексте**:

•Шаблон сравнивается с текстом справа налево.

•При несовпадении символов вычисляется сдвиг на основе таблиц bad_char и bmGs.

•При полном совпадении позиция добавляется в результат, и шаблон сдвигается для продолжения поиска.

Пример работы:

•**Текст**: «GCATCGAGAGAGAGTATACAGTACGCAGAGAG»

•**Шаблон**: «GCAGAGAG»

•**Результат**: [8,19] — позиции, где найдены вхождения шаблона.

5.Заключение

Алгоритм Бойера-Мура является одним из самых эффективных алгоритмов для поиска подстроки в тексте, особенно для больших объемов данных. Его основное преимущество заключается в использовании двух эвристик — правила плохого символа и правила хорошего суффикса, — которые позволяют значительно сократить количество сравнений.

Ключевые особенности:

•**Скорость** В лучшем случае алгоритм работает за линейное время $O(n/m)$, где n — длина текста, а m — длина шаблона.

•**Эффективность**: Алгоритм особенно полезен для поиска в больших текстах или при многократных поисках одного шаблона.

•**Гибкость**: Может быть адаптирован для различных задач, включая поиск с учетом регистра или использование wildcard-символов.

Реализация, представленная в коде, демонстрирует классический подход к алгоритму Бойера-Мура и может быть использована как основа для более сложных модификаций. Для дальнейшего улучшения можно оптимизировать предварительную обработку таблиц или добавить поддержку дополнительных правил.

GITHUB: https://github.com/sadPablik777/BoyMure
Оригинальная статья авторов: (я был в шоке что смог найти ее)
https://www.cs.utexas.edu/~moore/publications/fstrpos.pdf
https://www.geeksforgeeks.org/boyer-moore-algorithm-for-pattern-searching/
https://rosettacode.org/wiki/Boyer-Moore_string_search